# Wielowymiarowa analiza danych

Informatyka Społeczna WH AGH

2025-12-15

## Laboratorium

## Analiza wariancji

W niniejszej części skoncentrujemy się na jednoczynnikowej analizie wariancji (ANOVA).

Warunki przeprowadzenia eksperymentu:

- **Niezależność** : obserwowane wartości są od siebie niezależne. Jednym ze sposobów zapewnienia niezależności obserwacji jest dodanie losowości do procesu pobierania próbek.
- **Homoskedastyczność** : wariancje muszą być jednorodne, to znaczy zmienność reszt jest stała.
- **Normalność** : reszty powinny mieć rozkład normalny, czyli innymi słowy powinny mieć rozkład normalny.
- **Ciągłość** : zmienna zależna musi być ciągła.

### 1. Jednoczynnikowa analiza wariancji

**Analiza wariancji** (Analysis of Variance - ANOVA) to potężne narzędzie statystyczne stworzone w 1927 roku przez Ronalda Fishera. W wyniku regresji otrzymujemy model, ANOVA zaś stanowi jedną z metod jego oceny. Operacje realizowane w analizie ANOVA są ściśle powiązane z operacjami regresji. W rzeczywistości ANOVA to cała rodzina technik powiązanych wspólną analizą matematyczną.

Jednoczynnikowa analiza wariancji jest to najprostsze zastosowanie analizy ANOVA. Zakładając, że dysponujemy próbami danych z kilku populacji, zastanawiamy się, czy te populacje mają różne średnie. Odpowiedzi na to pytanie udziela właśnie jednoczynnikowa analiza wariancji.

W przypadku populacji o rozkładzie normalnym użyj funkcji `oneway.test` - w przeciwym razie skorzystaj z jej nieparametrycznej wersji `kruskal.test`

### 2. Przykłady zastosowania

1. Zapoznaj się z dokumentacją metody `oneway.test(x ~ f)`. Czym jest x, a czym f?
2. Wśród wyników znajdziemy wartość p. Przypomnij, jaką informację niesie ta wartość?

#### Dane zostały umieszczone w pliku `dane_gielda.xlsx`.

Zawiera on historyczne dane giełdowe. *Czy giełda papierów wartościowych przynosi większe zyski w określonych miesiącach*? Spróbujemy odpowiedzieć na to pytanie.

Dane są reprezentowane w ramce danych zawierającą kolumny: `r` oraz `mon`. Wektor czynnikowy `r` zawiera dzienne stopy zwrotu indeksu *Standard and Poor's 500,* czyli ogólną *metrykę wydajności giełdowej.* Wektor czynnikowy `mon` określa miesiąc kalendarzowy, w którym następowała zmiana.

Dane dotyczą okresu od 1950 do 2009 r.

3. Załaduj ten zbiór do RStudio.
4. Wykonaj kolejno polecenia:

```
oneway.test(r~mon, data = #TODO nazwa określająca ramkę z danymi)
```

5. Co uzyskaliśmy na wyjściu? Czy giełda pap. wartościowych znacząco zmienia się w zależności od miesiąca kalendarzowego?

W kolenym ćwiczeniu nieznacznie zmodyfikujemy powyższy przykład poprzez ograniczenie się do jedynie najnowszych danych. Będziemy starali się znaleźć odpowiedź na pytanie, czy *ogólny wzorzec zmienił się w ostatnim czasie?*

6. Wykorzystując **parametr subset** wyznacz 2500 indeksów najnowszych obserwacji (dane z mniej więcej 10 lat wstecz). Uzupełnij poniższy fragment kodu oraz wykonaj polecenie

```
oneway.test(r~mon, data = # TODO , subset = ...)
```

7. Przeanalizuj uzyskany rezultat. Jaką informację uzyskujemy (zwróć uwagę na wartość p)?

Jeżeli wiesz, że badane grupy mają takie same wariancje, możesz zdefiniować mniej zachowawczy test poprzez wyznaczenie parametru `var.equal = TRUE`:

```
oneway.test(x~f, var.equal = TRUE)
```

**Jednoczynnikową analizę ANOVA można przeprowadzić również wykorzystując funkcję `aov`, która zakłada zawsze równość wariancji**

```
m_x <- aov(x~f)
summary(m_x)
```

8. Zapoznaj się z dokumentacją wspomnianej funkcji.

Test ANOVA informuje, czy średnie grup są takie same lub odmienne. Nie określa jednak, które grupy są odmienne i nie wyświetla wartości tych różnic.

Różnice możemy jednak obliczyć, a także określić największe z nich przy pomocy funkcji `TukeyHSD`. Wykorzystanie tej funkcji zostanie zaprezentowane na przykładowych danych (wyżej), w których pogrupowaliśmy dzienne stopy zwrotów na podstawie dni tygodnia (wektor czynnikowy wday).

9. Ogranicz się w analizie do 2500 pierwszych (początkowych) obserwacji (odpowiada dekadzie 1950-1960).

   ```
   oneway.test(r~ #TODO )
   ```

10. Odczytaj, ile wynosi wartość p? Do jakich wniosków nas to prowadzi?

11. Wykonaj analizę ANOVA dla tego przypadku wykorzystując poznaną funkcję `aov()` oraz zapisz model pod zmienną `m`.

12. Zastosuj funkcję `TukeyHSD()` na uzyskanym obiekcie modelu (`m` jest argumentem wejściowym). Co uzyskaliśmy?

    **Komentarz do wyniku: Każdy rząd uzyskanej tabeli zawiera różnice pomiędzy średnimi dwóch grup (diff) oraz górną (upr), dolną (lwr) granicę przedziału ufności dla tej różnicy. Dla przykładu w pierwszym rzędzie tabeli zostaje porównana grupa Mon z grupą Fri: różnica pomiędzy ich średnimi wynosi 0,003 przy przedziale ufności (-0,0044, -0,0019).**

13. Analizując tabelę, wskaż pomiędzy którymi grupami zauważalne są największe różnice średnich?

*Zaletą funkcji TukeyHSD jest również możliwość graficznego przedstawienia wspomnianych różnic. Utwórzmy taką wizualizację wywołując:

```
plot(TukeyHSD(m))
```

*Linie poziome na wykresie ukazują przedziały ufności dla każdej pary. Dzięki takiemu graficznemu odwzorowaniu możemy szybko zauważyć, że kilka przedziałów ufności zawiera wartość 0, co oznacza, że dana różnica nie musi być istotna. Dostrzegamy tu także, że para Wed-Mon ma największą różnicę, ponieważ przedział ufności jest najbardziej przesunięty w prawo.*

## 3. Test Kruskala-Wallisa

Kolejny przykład: posiadamy dane podzielone na grupy. Ich rozkłady nie są normalne, ale wszystkie mają podobny kształt. Chcemy odpowiedzieć na pytanie, czy mediany grup znacząco różnią się pomiędzy sobą?

W przeciwieństwie do analizy ANOVA, wymogiem tego testu nie jest rozkład normalny danych:

```
kruskal.test(x~f)
```

14. Proszę zapoznać się z dokumentacją metody.

## 4. Porównywanie modeli za pomocą ANOVA

Intuicja: posiadamy dwa modele dopasowane do tych samych danych - chcemy wiedzieć, czy będziemy uzyskiwali za ich pomocą odmienne rezultaty.

Funkcja `anova()` może porównywać dwa modele i sprawdzać, czy są znacząco różne:

```
anova(m1, m2) # m1 - obiekt modelu 1, m2 - obiekt modelu 2
```

Podczas porównywania modeli jeden model musi być zawarty w drugim. Wszystkie człony mniejszego modelu muszą pojawić się w modelu większym. W przeciwnym wypadku, nie będzie można przeprowadzić porównania. Analiza ANOVA przeprowadza test F - wykonywany pomiędzy modelami.